Comment GMIC prépare vos mammographies

Guide visuel du prétraitement — de l'image brute au format d'inférence

Pourquoi prétraiter ?

Une mammographie brute ne peut pas être envoyée directement au modèle GMIC. Entraîné sur un corpus précis (INbreast / CBIS-DDSM), GMIC s'attend à recevoir des images dans un format très spécifique : taille fixe, fond noir supprimé, niveaux d'intensité normalisés.

Quatre étapes transforment vos images brutes en ce format :

Étape	Ce qu'elle fait	Où
1. Conversion DICOM → PNG	Extrait les pixels du format médical	`preprocess.py`
2. Construction du PKL	Organise les examens dans la structure GMIC	`preprocess.py`
3. Recadrage	Supprime le fond noir autour du sein	`preprocess.py`
4. Resize 2944×1920	Uniformise la taille de toutes les images	`preprocess.py`
— Flip + normalisation	Aligne les seins et centre la distribution	`inference.py`

> Le flip horizontal et la normalisation mean/std sont appliqués à la volée lors de l'inférence — inutile de les précalculer ni de les stocker sur disque.

Ce notebook illustre les 4 étapes de prétraitement sur vos images.

Étape 1 — Conversion DICOM → PNG

Les mammographies médicales sont souvent stockées au format **DICOM** (`.dcm`), un format qui encapsule bien plus que l'image : identité du patient, paramètres du scanner, métadonnées EXIF…

Cette étape extrait les pixels bruts et les sauvegarde en **PNG 16-bit**. Elle corrige aussi une particularité de certains scanners qui stockent les niveaux inversés (**MONOCHROME1**) : sans correction, le tissu mammaire apparaîtrait en noir sur fond blanc — l'inverse de ce qu'attend GMIC.

```
# preprocess.py · ligne 112
if ds.PhotometricInterpretation == "MONOCHROME1":
    arr = arr.max() - arr   # inverse les niveaux : blanc  noir
```

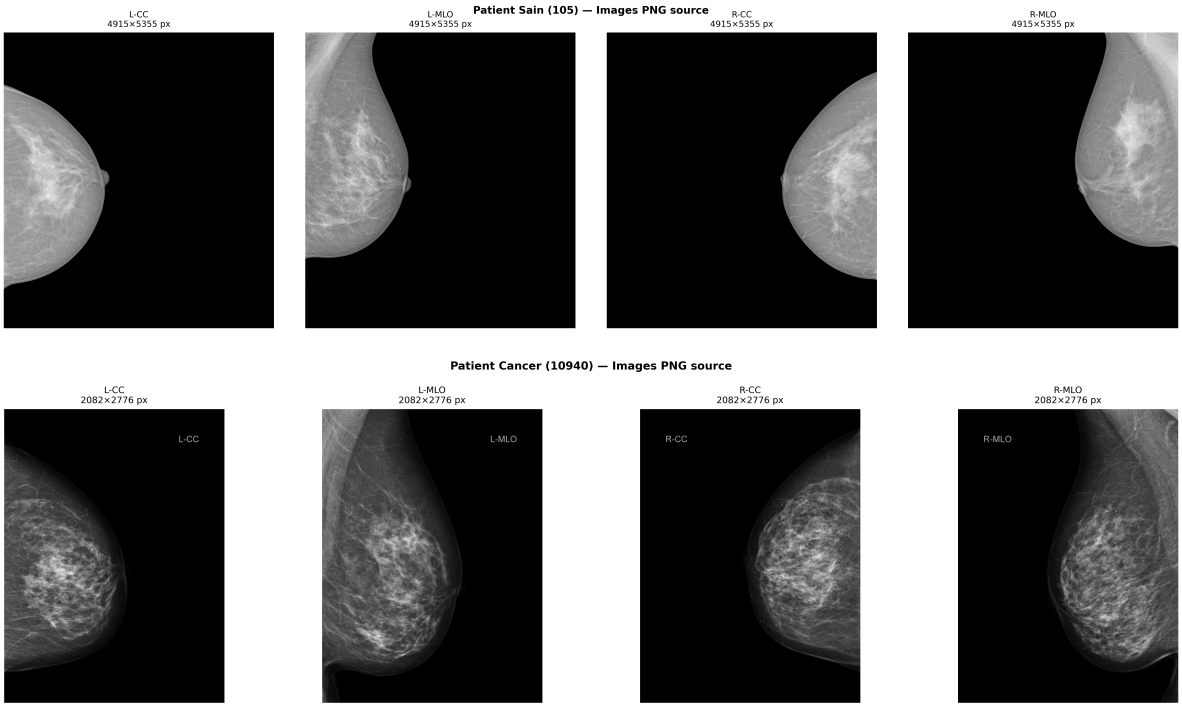
> Si vos images sont déjà en PNG (comme les données `data/sample/`), cette étape est ignorée automatiquement.

Métrique	Valeur
Examens chargés	2
Examens complets (4 vues)	2
dont cancer	1
dont sains	1
Images totales référencées	8

Tous les examens ont les 4 vues.

Aperçu des images avant traitement

Les images ci-dessous sont les PNG tels qu'ils arrivent dans votre `INPUT_DIR`, avant tout traitement. On y voit les 4 vues standard d'une mammographie : **CC** (cranio-caudale, de dessus) et **MLO** (médio-latérale oblique, de côté), pour chaque sein (L = gauche, R = droite).



Étape 2 — Construction du PKL GMIC

GMIC n'accède pas aux fichiers image directement : il attend un fichier **`.pkl`** (Python pickle) qui décrit tous les examens dans une structure précise.

Pour chaque patient, ce fichier liste : - les chemins vers les 4 images (une par vue), - le label cancer (`malignant : True/False`), - les métadonnées nécessaires aux étapes suivantes.

Cette étape lit votre `train.csv` et construit ce fichier pickle. C'est la "colonne vertébrale" que toutes les étapes suivantes vont enrichir.

```
# preprocess.py · lignes 150-154
"cancer_label": {
    "malignant":       0,   # ← 1 si le patient a un cancer (n'importe quel côté)
    "left_malignant":  0,   # ← 1 si cancer côté gauche
    "right_malignant": 0,   # ← 1 si cancer côté droit
    ...
}
```

Ces labels sont lus depuis la colonne `cancer` de votre `train.csv` et propagés par latéralité. L'inférence les réutilise pour calculer l'AUC-ROC.

Étape 3 — Recadrage (`crop_mammogram`)

Une mammographie brute contient beaucoup de **fond noir** autour du sein. Ce fond perturbe GMIC : entraîné sur des images recadrées, il obtient de moins bonnes performances si le fond noir est présent.

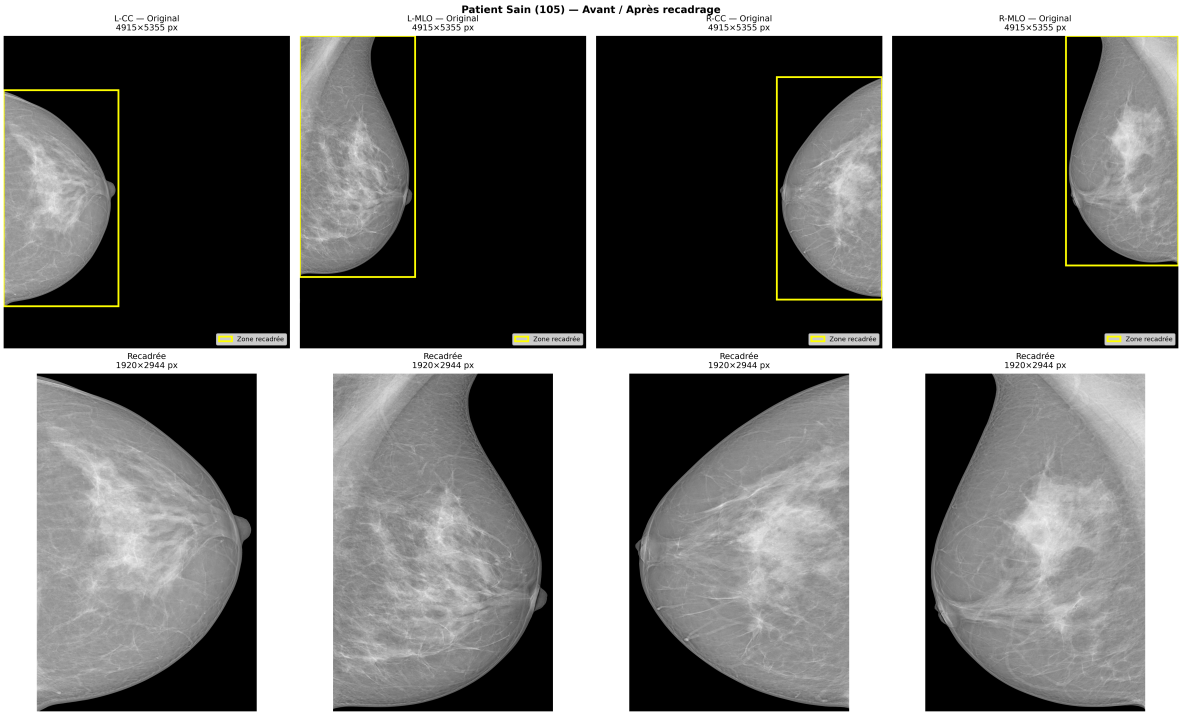
`crop_mammogram` détecte automatiquement le tissu mammaire par seuillage et supprime les bords noirs. Il mémorise dans le PKL la `window_location` — les coordonnées exactes de la zone découpée dans l'image originale.

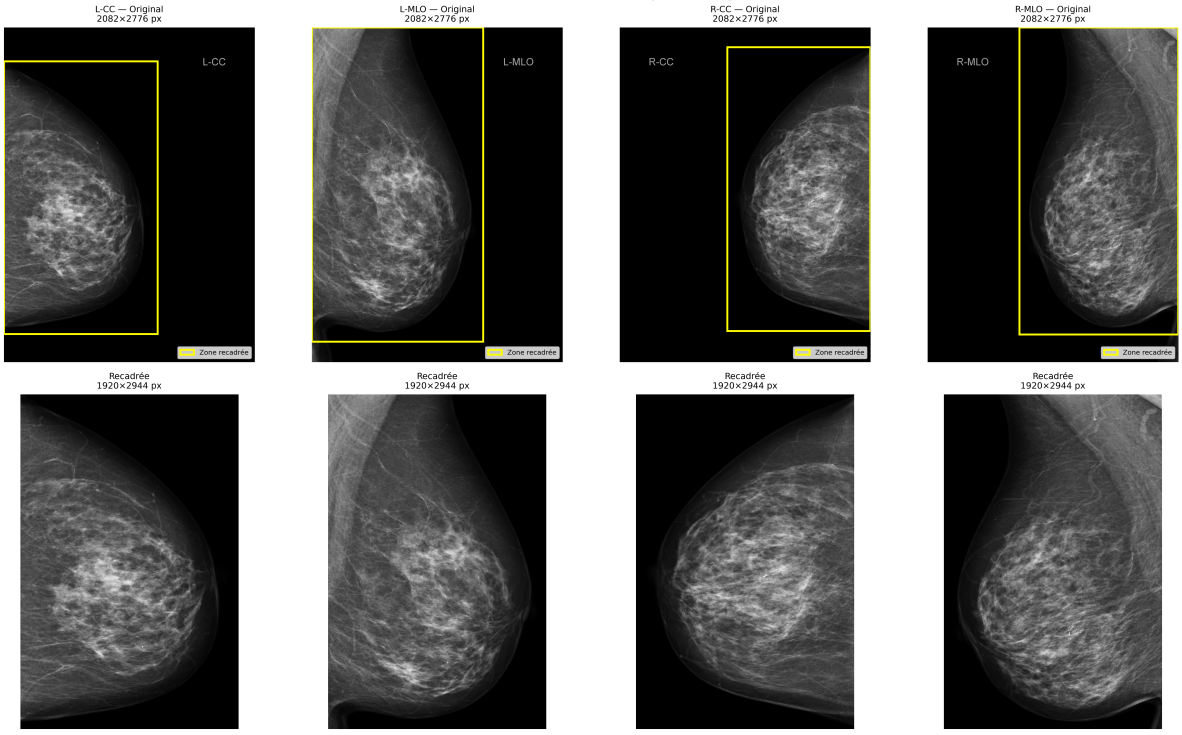
```
# preprocess.py · lignes 210-215
src/cropping/crop_mammogram.py
    --input-data-folder  <png_dir>         # images PNG sources
    --output-data-folder <cropped_dir>     # où écrire les PNG recadrés
    --exam-list-path     <pkl_raw>         # PKL d'entrée (construit à l'étape 2)
    --cropped-exam-list-path <pkl_crop>    # PKL de sortie (avec window_location)
    --num-processes 4                      # parallélisation sur 4 cœurs
```

`crop_mammogram` est le script GMIC original — on l'appelle en sous-processus pour réutiliser exactement la même logique que les auteurs du papier.

Avant et après recadrage

Le **rectangle jaune** sur l'image originale (ligne du haut) montre la zone que `crop_mammogram` a extraite. L'image recadrée (ligne du bas) est le résultat.


Patient Sain (105) — Avant / Après recadrage
L-CC — Original
4915×5355 px
L-MLO — Original
4915×5355 px
R-CC — Original
4915×5355 px
R-MLO — Original
4915×5355 px
Zone recadrée
Recadrée
1920×2944 px
Recadrée
1920×2944 px
Recadrée
1920×2944 px
Recadrée
1920×2944 px


Patient Cancer (10940) — Avant / Après recadrage
L-CC — Original
2082×2776 px
L-MLO — Original
2082×2776 px
R-CC — Original
2082×2776 px
R-MLO — Original
2082×2776 px
L-CC
L-MLO
R-CC
R-MLO
Zone recadrée
Recadrée
1920×2944 px
Recadrée
1920×2944 px
Recadrée
1920×2944 px
Recadrée
1920×2944 px

Étape 4 — Resize 2944×1920 + normalisation

Après recadrage, les images ont des **tailles variables** selon les scanners (certains produisent 3000×2500, d'autres 2000×1600…).

GMIC a été entraîné sur des images de taille exactement **2944×1920 pixels**. Toutes les images sont donc redimensionnées à cette taille, puis normalisées en **uint8** (valeurs entières de 0 à 255).

Ces deux contraintes — taille fixe et type uint8 — sont des prérequis stricts : un modèle PyTorch ne peut pas traiter un batch d'images de tailles différentes, et les poids ont été appris avec cette plage de valeurs.

```
# preprocess.py · lignes 279-280
interp = cv2.INTER_AREA if (h > GMIC_H or w > GMIC_W) else cv2.INTER_LINEAR
img_resized = cv2.resize(img, (GMIC_W, GMIC_H), interpolation=interp)
```

> **Pourquoi deux interpolations ?** `INTER_AREA` (réduction) évite l'aliasing quand on rétrécit — il moyenne les pixels voisins. `INTER_LINEAR` (agrandissement) interpole en bilinéaire quand on agrandit — il est plus doux que le voisin le plus proche.

Vérification		Résultat
Images vérifiées		8
Taille	1920×2944	OK — toutes conformes
Type	uint8	OK — toutes conformes

Récapitulatif

À l'issue des 4 étapes, chaque examen est représenté par :

- **4 images PNG** de 2944×1920 px, normalisées en uint8, dans `cropped_images/`
- **`data.pkl`** — copie de `cropped_exam_list.pkl`, prêt pour l'inférence

À l'inférence (`make infer`), chaque image subit à la volée : 1. **Flip horizontal** des vues droites (R-CC, R-MLO) — tous les seins regardent à gauche 2. **Normalisation mean/std** — centre la distribution sur ~N(0,1) pour le modèle

Étape	Fichier	Examens	Complets	Images
1–2 Après conversion + PKL	exam_list_before_cropping.pkl	2	2	8
3 Après recadrage	cropped_exam_list.pkl	2	2	8
4 Après resize	data.pkl	2	2	8
PNG sur disque	cropped_images/	—	—	8

Pour relancer ce prétraitement :

```
make preprocess INPUT_DIR=data/sample/train_images OUTPUT_DIR=output/sample
make infer      OUTPUT_DIR=output/sample
```